

Simple PDF

Martín Goñi

10/2/2026

¿Que es SPF?

Simple PDF, es un DSL para generar PDFs, es decir un lenguaje que al ser interpretado produce PDFs, este informe está hecho con SPF. Decidí hacer SPF porque me interesaba hacer un proyecto que hiciese algo más que dar salida a la consola. Considerando que desde que conocí LaTeX me interesó el typesetting este proyecto era la excusa ideal para interiorizarme más en el tema.

Consideraciones de diseño

A la hora de diseñar SPF me inspire en LaTeX, pero sin mantenerme atado a sus convenciones o decisiones de diseño, lo trate como una fuente de inspiración. En particular toma otra dirección en cuanto a la forma de los comandos, permitiendo solo un argumento. Junto con esto las opciones deben tener asociada una clave indicando a qué campo corresponde el valor, hice esto porque la forma de escribir opciones en LaTeX es confusa; Se pueden combinar opciones con y sin clave, algo que en mi opinión es confuso y se presta a errores. Finalmente simplifique la forma en la que estructura el documento, eliminando commands y ambientes que son innecesarios en un DSL sencillo.

Los comandos implementados son un subconjunto de los disponibles en LaTeX, elegidos para permitir generar documentos (mayormente) completos, manteniendo al mismo tiempo la cantidad total de comandos baja. Cabe notar que los nombres y argumentos de los comandos no se copiaron exactamente, mi objetivo era que este subconjunto tenga una *funcionalidad* similar a la de sus contrapartes en LaTeX.

Sintaxis

Para representar la sintaxis se usan ciertas convenciones; El símbolo *** indica cero o más ocurrencias de lo que encierra mientras que el *+* indica una o más ocurrencias. Los comentarios no están incluidos pues no son parte de la sintaxis en si, son añadidos para la conveniencia del usuario y no resultan en tokens al parsear. A continuación se presenta la sintaxis concreta de SPF:

```
digit      ::= '0' | '1' | ... | '9'
integer    ::= <digit> (<digit>)*
float      ::= <integer> '.' <integer>
letter     ::= 'a' | ... | 'z' | 'A' | ... | 'Z'
letterStr  ::= <letter> (<letter>)*
specialChars ::= '\' | '{', '}' | '[' | ']' | '"' | '/' | '|'
nonSpecialChars ::= c / c != <specialChars>
filepath   ::= (<letterStr> | '/' | '\' | '-' | '_' | '.' | ' ')+

#| Opciones
optionList  ::= '[' optionListElems ']'
optionListElems ::= <optionPair> (',' <optionPair>)*
optionPair  ::= <letterStr> ':' <optionValue>
optionValue ::= <boolValue>
              | <numberValue>
              | <literalValue>
              | <identifierValue>

boolValue   ::= 'true' | 'false'
numberValue ::= <integer> | <float>
literalValue ::= '"' <nonSpecialChars> '"'
identifierValue ::= <letterStr>

#| Texto
text        ::= ('\bold' | '\italic' | '\emph') '{' <textChars> '}'
textChars   ::= (<nonSpecialChars>)+ <textChars> | '\' <specialChars> <textChars> |
<empty>

#| Configuración del documento
config      ::= '\config{' <configName> '}' <optionList>
```

```

configName ::= 'size' | 'pagenumbering' | ... | 'verbnumbering'

#| Metadata del documento
metadata   ::= <title> <author> <date>
title      ::= '\title{' <text> '}' | <empty>
author     ::= '\author{' <text> '}' | <empty>
date       ::= '\date{' <text> '}' | <empty>

#| Comandos
command    ::= <text>
            | <paragraph>
            | <section>
            | <subsection>
            | <figure>
            | <table>
            | <list>
            | <verb>
            | <newpage>
            | <hline>

paragraph  ::= '\begin{paragraph}' <optionList> <text> '\end{paragraph}'
section    ::= '\section{' <text> '}' <optionList>
subsection ::= '\subsection{' <text> '}' <optionList>
figure     ::= '\figure{' <filepath> '}' <optionList>
table      ::= '\begin{table}' <optionList> <tableContents> '\end{table}'
tableContents ::= <text> ('|' <text>)* '\break'
list       ::= '\begin{list}' <optionList> <listContents> '\end{list}'
listContents ::= '\item' <text>
verb       ::= '\begin{verb}' <optionList> (<anyChar>)+ '\end{verb}'
newpage    ::= '\newpage'
hline      ::= '\hline' <optionList>

#| Documento
document   ::= (<config>)* <metadata> (<command>)+

```

Funcionamiento

Para mantener el sistema lo más modular posible SPF está dividido en componentes, cada una independiente de las demás. Dado un archivo en formato SPF este atraviesa una serie de módulos para producir un PDF, en orden, son:

1. Parser: Se encuentra en `Parser.hs`. Se encarga de *parsear* el archivo, es decir convertir el texto del mismo en un AST. Cabe notar que en este punto no se validan los datos, el parser solo se ocupa de la correctitud *sintáctica* del archivo, no la *semántica*. Puede fallar.

2. Validador: Está compuesto por múltiples archivos, se encuentran en el directorio `Validation`. Valida los contenidos del AST generado por el parser. El trabajo principal del validador es verificar que las opciones en el archivo, tanto de configuración como de los comandos sean correctas; Esto conlleva verificar que cada par `clave:valor` sea del tipo y forma correcta para el comando o la configuración a él que corresponden. Devuelve otro AST y puede fallar.

3. Recursos: Se encuentra en `Resources.hs`. Carga todos los recursos necesarios para typesetter el documento. Por un lado están las fuentes, deben cargarse siempre, si esto falla el typesetting no puede realizarse. Por el otro lado están los recursos especificados por el usuario, también deben ser cargados antes de comenzar a type setear el documento, esta carga puede fallar.

4. Typesetter: El último eslabón de la cadena, toma el AST producido por el validador junto con los recursos cargados y los utiliza para generar un PDF.

Un poco más sobre ASTs

En un principio los ASTs usados simplemente almacenaban una lista de todos los comandos utilizados en el documento. Rápidamente me di cuenta de que esto era una mala idea. En primer lugar no había separación entre los distintos tipos lógicos de tokens, todos eran *comandos* en una lista. Lo que llevaba a un segundo problema era necesario iterar repetidas veces sobre esta lista para obtener distintos tipos de tokens. Hacer esto es ineficiente y no escala bien.

Para solucionar esto los ASTs se separaron en componentes funcionales, donde cada una corresponde a un tipo de comando. De esta forma hay una separación lógica entre los tokens; Al mismo tiempo solo se tira sobre una lista cuando es necesario recorrerla, mejorando la eficiencia y haciendo más rápido el programa.

¿Como fallar?

Cómo manejar fallos en un programa de este tipo no es una pregunta fácil de resolver, principalmente porque es posible tener *muchos* fallos. Sería entonces ideal poder acumular todos los errores que ocurren mientras el programa procesa un archivo; De esta forma el usuario podría solucionar múltiples errores al mismo tiempo, haciendo que se deba ejecutar el programa menos veces. Esto sin embargo no es posible, al menos del todo. No se pueden acumular errores de distintas secciones pues cada módulo depende de que el resultado de los anteriores sea correcto. Llegamos así a un compromiso, si bien no podemos acumular *todos* los errores a lo largo del programa si podemos acumular los errores de cada etapa.

En el parser esto se hace usando *delayed parse errors*. Estos son errores que no provocan que el parser falle inmediatamente, los errores acumulados se toman en cuenta al final del paseo, donde sí hay por lo menos uno el parser falla. Cabe notar que es posible obtener un error, que haga que el parser falle inmediatamente, esto puede ocurrir por uno de dos motivos. Por un lado los *delayed parse errors* deben implementarse manualmente; No es posible cubrir todos los casos, se cubrieron los errores más comunes y fáciles de producir. Por el otro lado no siempre es posible recuperarse de un error de parseo, generalmente debido a que el fallo deja contenido sin consumir del archivo, este contenido no encaja con ninguna de las reglas del parser, por lo que no puede seguir. A continuación se presenta un ejemplo:

```
\sectio{Digital Typography}
^
Posición del cursor
```

El comando `\sectio` es invalido, al parsearlo el parser produce un *delayed parse error* y se recupera, continuando el parseo:

```
\sectio{Digital Typography}
      ^
      Posición del cursor
```

El comando `{Digital ...}` es invalido, mas aun este error no es un error del que el parser se pueda recuperar, ya que al fallar el parser de comandos no hay ningún parser que consuma `{Digital ...}`. Si bien se podría hacer que al fallar el parser de comandos consuma la string restante, esto corre el riesgo de generar mensajes de error más confusos para el usuario. En el caso de un bloque `begin/end`, se consumiría el inicio del bloque pero no el fin, generando un mensaje de error inapropiado cuando el parser encuentre `\end{ ... }`.

El resto de los módulos utiliza el paquete `Validation`, su descripción es bastante autoexplicativa: *A data-type like Either but with an accumulating Applicative*. Es decir cumple la misma función que `Either`, dándonos un resultado o un error, pero permitiéndonos acumular errores de forma fácil; Esta facilidad viene de la mano de que el acumulador de errores es un functor aplicativo, lo que permite concatenar validaciones fácilmente mediante.

Generando PDFs

Una vez que se tiene un AST valido falta la parte más importante, transformarlo en un PDF. Para hacer esto utilice la librería HPDF. Elegí esta librería por un motivo simple, es la única librería para generar PDFs escrita en Haskell.

Habiendo usado esta librería puedo decir que si bien es muy poderosa *tiene problemas*, el principal y del cual derivan la mayoría es que es una librería con muy pocos usuarios. Como consecuencia de esto hay muy poca información sobre la librería. La documentación está incompleta, muchas funciones tienen explicaciones muy pobres, si es que tienen. Sumado a esto nunca se explica la estructura o flujo general de un programa hecho con HPDF, ni cómo se conectan los distintos componentes de la librería.

Lo que me permitió entender cómo funciona la librería fue el archivo de prueba en el repositorio del proyecto(github.com/hsyl20/HPDF/blob/master/Test/test.hs). Este prueba casi todas las funciones de la librería generando un documento. Me permitió ver un ejemplo en funcionamiento de la misma al mismo tiempo que me permitía experimentar y realizar cambios para ver *exactamente* cómo funcionaba la librería.

Un bug en HPDF

Mientras estaba escribiendo un informe descubrí un bug en HPDF, provoca que dadas ciertas condiciones el algoritmo de *line breaking* no funcione. Gracias a errores de redondeo de punto flotante puede ocurrir que una palabra no sea lo suficientemente larga como para causar un *line break* pero que si sea lo suficientemente larga como para exceder el margen de la caja donde está siendo typeseteadada. Esto causa que el algoritmo deje de introducir *line breaks* por completo.

En la figura de abajo se ve como el bloque de texto “autoexplicativa:” excede levemente el margen derecho, causando el bug antes descrito. Notar que esto no ocurre siempre, solo cuando un bloque de texto y la línea generan una combinación *problemática*. En base a mi entendimiento de la librería para solucionar este bug es necesario modificar el código fuente de la misma, algo que excede el alcance del trabajo.




Figure 1: Un ejemplo del error

¿Como hacer typesetting?

Typesetting es el proceso de organizar, formatear y disponer texto y elementos gráficos asociados en una página, se busca mejorar la legibilidad y estética. Si esto se hace bien los lectores no van a darse cuenta de que lo que están leyendo fue organizado de forma rígida y poco natural.

Donald E. Knut, Digital Typography (1999)

El algoritmo

El problema a solucionar es: Dada una serie de elementos como mejor colocarlos en una(o más) páginas de forma que el resultado sea estético y legible. Para simplificar el diseño utilizamos una abstracción, en lugar de elementos discretos pensamos en **cajas**, no importa que contengan(Texto, figuras, tablas, etc), lo importante es su tamaño. Considerando esto el algoritmo de typeseteeo puede separarse en dos sub-algoritmos, vertical y horizontal.

El primer algoritmo es fácil de implementar usando un cursor vertical. Este determina la posición vertical de los elementos a typesetter, luego de typesetar cada elemento este cursor se incrementa de acuerdo al tamaño del elemento y el *before and after spacing*. Estos últimos son espacio vacío añadido antes y después de cada elemento para hacer el resultado más estético. Antes de typesetear un elemento se verifica que haya suficiente espacio en la página, si no es así se crea una página nueva. Notar también que cada función de typeseteo es encargada de mover el cursor. Una aproximación en pseudocódigo es:

```
1 typeset [] = done
2 typeset (elem:xs) =
3     when checkSpace makeNewPage
4
5     case elem of
6         Paragraph p -> typesetParagraph p
7         ...
8         List l -> typesetList l
9         ...
10        Newpage -> makeNewPage
```

El segundo algoritmo es significativamente mas complejo, para una explicación en detalle ver *Donald E. Knut*, “Breaking Paragraphs Into Lines” *Digital Typography* (1999). Afortunadamente no fue necesario implementar este algoritmo, el modulo `Typesetting` de HPDF, posee funciones que implementan el algoritmo antes mencionado; Estas son `fillContainer` y `displayFormattedText`. Ambas funciones cumplen la misma función, reciben un estilo, un contenedor y un bloque de texto; Este será typeseteadado dentro de los límites fijados por el contenedor, con el estilo dado.

Si bien la segunda función es más sencilla de usar tiene una limitación importante, si el texto dado no entra completamente en el contenedor lo descarta, `fillContainer` por el otro lado retorna el contenido que no se pudo typesetear. Debido a esto es usada para typesetear casi todos los elementos del documento.

Las estructuras

A la hora de implementar el algoritmo quedó claro que era necesario mantener un estado a medida que se genera el documento. En un principio utilice una monada `StateT` para almacenar todos los datos. Si bien esto funcionaba presentaba un problema conceptual, esta monada tenía valores que eran solo de lectura, como la configuración; Sin embargo debido al tipo de la monada podían ser modificados.

Para solucionar esto se usan dos monadas concatenadas, primero una monada `ReaderT`, su *environment* almacena los valores solo de lectura y su monada es `StateT`. A su vez esta almacena en su *state* a todos los valores dinámicos, su monada la monada `PDF` que almacena el documento que está siendo typeseteadado. En Haskell esto se expresa de la siguiente forma:

```
type Typesetter a = ReaderT RenderEnv (StateT RenderState PDF) a
```

En cuanto a las estructuras `RenderEnv` y `RenderState` la único notable es que todos sus campos, menos uno, son estrictos. De lo contrario un PDF largo podría llenar la RAM o causar un *Stack Overflow* debido a thunks sin evaluar.

Desafios

Validando de forma eficiente

A la hora de validar los contenidos del AST generado por el parser me encontré con un problema, cómo hacer esto de forma fácil y escalable. La primera solución implementada era simple pero no escalable, se basaba en escribir todas las permutaciones posibles para cada comando. Esta es la implementación original de la validación de la opcion de configuracion `pagesize`, con la opcion `custom`:

```

1  [("width", PInt w), ("height", PInt h)] -> Success $ VPageSize (SizeCustom
   (fromIntegral w) (fromIntegral h))
2  [("width", PFloat w), ("height", PFloat h)] -> Success $ VPageSize (SizeCustom w h)
3  [("width", PFloat w), ("height", PInt h)] -> Success $ VPageSize (SizeCustom w
   (fromIntegral h))
4  [("width", PInt w), ("height", PFloat h)] -> Success $ VPageSize (SizeCustom
   (fromIntegral w) h)
5  [("height", PInt h), ("width", PInt w)] -> Success $ VPageSize (SizeCustom
   (fromIntegral w) (fromIntegral h))
6  [("height", PFloat h), ("width", PFloat w)] -> Success $ VPageSize (SizeCustom w h)
7  [("height", PFloat h), ("width", PInt w)] -> Success $ VPageSize (SizeCustom
   (fromIntegral w) h)
8  [("height", PInt h), ("width", PFloat w)] -> Success $ VPageSize (SizeCustom w
   (fromIntegral h))

```

Estaba claro que este método no era viable, no escalaba en lo más mínimo. Después de intentar varias ideas, llegue a una solución que es tanto simple como escalable, gracias al uso de funtores aplicativos. Se presenta abajo:

```

1  newtype Schema a = Schema {
2      runSchema :: [POptionPair] -> Validation [String] a
3  }
4
5  instance Functor Schema where
6      fmap f (Schema g) = Schema (\o -> fmap f (g o))
7
8  instance Applicative Schema where
9      pure x = Schema (\_ -> Success x)
10     (Schema f) <*> (Schema g) = Schema (\o -> f o <*> g o)

```

La solución que diseñe se basa en los `Schema`, son estructuras que encapsulan una función que transforma opciones, en la forma de una lista de `POptionPair`, en una `Validation`. La instancia de funtores aplicativos es lo que hace escalable a este diseño, pues múltiples validaciones pueden concatenarse mediante `<*>`. Al mismo tiempo también se utilizan funciones de validación genéricas, que permiten ver si una clave de cierto tipo esta presente y/o si cumple una condición dada. A modo de comparación presentamos la version actual del validador de `pagesize`, con la opción `custom`:

```

1  ensureValidKeys "Invalid custom size" ["width", "height"]
2      (SizeCustom <$> requireFloatWith "width" (validateNumInst (> 0) Pt) "Width > 0"
3      <*> requireFloatWith "height" (validateNumInst (> 0) Pt) "Height > 0"
4      <&> \x -> setLayout (\c -> c { pageSize = Just x }))

```

Bookmarks

Cuando se crea una sección o subsección también se crea una *bookmark* en el PDF, esto es un link que lleva a el lugar donde se encuentra la sección o subsección, según corresponda; El problema es la forma en la que la referencia se pasa a la función usada:

```

1  newSectionWithPage :: Text -> Maybe Color -> Maybe OutlineStyle -> PDFReference
   PDFPage -> PDF () -> PDF ()

```

El último argumento de esta función es el elemento al que debe hacer referencia el link, sin embargo no es posible pasar el elemento de forma directa. Esto se debe a que la función de typeseteo no retorna un `PDF ()`, sino un `Typesetter ()`. La solución a este problema sería realizar el typeseteo del elemento dentro del *scope* de `newSectionWithPage`. El problema con esto es que al hacer eso se pierde el estado actualizado de `StateT`.

La solución para “sacar” el estado del *scope* sería usar `liftIO` y una referencia, sin embargo la monada `PDF ( )` no tiene una instancia de esta. Intente luego utilizar `unsafePerformIO` dado que la generación del PDF es secuencial, sin embargo esto llevaba a un deadlock:

```
1 | SPF-exe: thread blocked indefinitely in an MVar operation
```

Segun mi entendimiento esto ocurre ya que Haskell utiliza evaluación *lazy*, donde el thread principal espera el resultado del `unsafePerformIO`, mientras que el thread que debe producir ese resultado no se ejecuta pues Haskell es lazy; Lo que produce un deadlock.

Considerando esta limitación decidí no pasarle ninguna referencia a `newSectionWithPage`, esto causa que el link lleve al principio de la página donde esta el elemento, no el elemento en sí. Si bien no es una implementación ideal la considero suficiente, dado que la función principal de las *bookmarks* es la navegación a la página correspondiente con la cabecera.

Tests

Para probar el proyecto utilice `HSpec`, un framework para realizar *testing* en Haskell. Lo elegi entre las alternativas dado que los tests se escriben utilizando un DSL muy sencillo, haciendo el proceso rapido y facil. Los tests no se incluyeron en la descripcion del funcionamiento del programa pues no son parte de este, son un anexo que permite identificar errores en el mismo.

Escribir tests para los modulos `Parser` y `Validation`, usando `HSpec`, fue sencillo. En ambos las funciones que exponen estos modulos devuelven un resultado o un error. Podemos asi verificar facilmente si una funcion se comporta correctamente analizando cual de los dos casos retorna.

¿Como validamos un PDF?

Si bien existen multiples formas de validar un PDF ninguna es ideal en el contexto dado:

El test mas simple posible solo verifica que el typesetter produzca un resultado, no analiza su contenido para ver si es correcto. Si bien es muy simple de implementar no verifica nada util, debido a la forma en la que esta estructurado el proyecto el typesetter no produce errores(Exceptuando un error interno, que no tiene realacion con el documento).

Una alternativa es verificar el contenido del PDF, en particular se extrae el texto del PDF producido y se lo compara con el resultado esperado. Si bien esto permite identificar situaciones donde hay contenido que no se ha typesetado este tipo de errores son infrecuentes. La mayor parte del tiempo el problema yace en que el contenido esta formateado de forma incorrecta, algo que este tipo de test no detecta.

Finalmente considere un test de comparacion, donde se compara el resultado del typesetter contra un “PDF patron”, cuyos contenidos han sido verificados manualmente. Si bien esto *puede* funcionar es una solucion propensa a fallar, los PDFs suelen contener *timestamps* e IDs aleatorias, al mismo tiempo diferencias en la compresion de los documentos pueden afectar los bytes de los archivos pero no el contenido.

Dadas las limitaciones de los metodos mencionados decidi no añadir tests al typesetter, considere suficiente a todas las pruebas realizadas a lo largo de la elaboracion del trabajo y este informe.

Recursos usados

Recursos usados sobre *typesetting*:

- *Donald E. Knut, Digital Typography (1999)*
- *Paul E. Justus, “There is more to typesetting than setting type” IEEE Transactions on Professional Communication PC-15 (1972)*

Recursos usados sobre Megaparsec:

- <https://hackage.haskell.org/package/megaparsec>
- <https://markkarpov.com/tutorial/megaparsec.htm>
- <https://serokell.io/blog/parser-combinators-in-haskell>

Recursos usados sobre `unsafePerformIO`:

- <https://hoogle.haskell.org/?hoogle=unsafePerformIO>
- <https://www.cs.tufts.edu/comp/150PLD/Notes/IOMonad.pptx>
- <https://discourse.haskell.org/t/using-unsafeperformio-safely/4146>

Recursos usados sobre `HSpec`:

- <https://hspec.github.io/writing-specs.html>
- <https://hspec.github.io/expectations.html>